


Dept. de Ciència de la Computació i Intel·ligència Artificial  
Dpto. de Ciencia de la Computación e Inteligencia Artificial




Universitat d'Alacant  
Universidad de Alicante

Sistemas Inteligentes


# TEMA 5: Árboles de Decisión y Redes Bayesianas

TEMA 5: Árboles de Decisión y Redes Bayesianas1

1



Dept. de Ciència de la Computació i Intel·ligència Artificial  
Dpto. de Ciencia de la Computación e Inteligencia Artificial



Universitat d'Alacant  
Universidad de Alicante

Sistemas Inteligentes

## Parte 1: Árboles de decisión

- Árboles de decisión
  - Planteamiento del problema
  - Ejemplo: Concesión de créditos
  - Entropía y Ganancia de Información
- Algoritmo ID3
  - Algoritmo recursivo
  - Aplicación al ejemplo
  - Consideración de atributos numéricos
  - Atributos con un gran número de valores

TEMA 5: Árboles de Decisión y Redes Bayesianas2

2

Dept. de Ciència de la Computació i Intel·ligència Artificial  
 Dpto. de Ciencia de la Computación e Inteligencia Artificial  
 Universitat d'Alacant  
 Universidad de Alicante

Sistemas Inteligentes

## Árboles de decisión

■ **Características:**

- Estructura para **clasificación** de vectores de atributos.
- Establece **en qué orden** testar los atributos para conseguir la clasificación del vector de entrada.
- Para componer dicho orden se eligen primero aquellos atributos que **mejor ganancia de información** prometen a efectos de descubrir la clase del vector de entrada.
- Es interesante **aprenderlos** a partir de un conjunto de vectores

```

graph TD
    A((Moroso)) -- Si --> B[No conceder]
    A -- No --> C((Ingresos  
Eur./mes))
    C -- "<600" --> D[No conceder]
    C -- "600-1200" --> E((Trabajo fijo))
    C -- ">1200" --> F[Conceder]
    E -- Si --> G[Conceder]
    E -- No --> H[No conceder]
      
```

TEMA 5: Árboles de Decisión y Redes Bayesianas

3

3

Dept. de Ciència de la Computació i Intel·ligència Artificial  
 Dpto. de Ciencia de la Computación e Inteligencia Artificial  
 Universitat d'Alacant  
 Universidad de Alicante

Sistemas Inteligentes

## Ejemplo “Concesión de créditos”

Cliente	Moroso	Antigüedad (años)	Ingresos (Eur./mes)	Trab.fijo	Conceder
1	sí	>5	600-1200	sí	no
2	no	<1	600-1200	sí	sí
3	sí	1-5	>1200	sí	no
4	no	>5	>1200	no	sí
5	no	<1	>1200	sí	sí
6	sí	1-5	600-1200	sí	no
7	no	1-5	>1200	sí	sí
8	no	<1	<600	sí	no
9	no	>5	600-1200	no	no
10	<b>sí</b>	1-5	<600	no	no

■ **Aprendizaje:**

- ¿Por qué atributo **comenzar** primero?
- Esquema voraz: Elegir uno y **filtrar recursivamente**.

TEMA 5: Árboles de Decisión y Redes Bayesianas

4

4

Dept. de Ciència de la Computació i Intel·ligència Artificial  
 Dip. de Ciència de la Computació i Intel·ligència Artificial  
 Universitat d'Alacant  
 Universitat de Alicante


Sistemas Inteligentes

## Entropía

■ **Definición:**

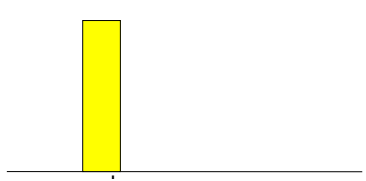
- Medida del **grado de incertidumbre** asociado a una distribución de probabilidad.
- En una **distribución uniforme**, todos los valores son igualmente probables  $P_i = 1/N$  y por tanto la **entropía es máxima**, lo cual indica máxima incertidumbre.
- Por el contrario, en una **distribución pico** en la que  $P_i = 1$  y  $P_j = 0$ , para todo  $j \neq i$  la entropía es mínima lo cual indica mínima incertidumbre o sea **máxima información**.

$$E(S) = \sum_{i \in C} -p_i \log_2 p_i$$



si                      no

$-0.51 \log_2(0.5) - 0.51 \log_2(0.5) = 1$



si

$-1.01 \log_2(1.0) - 0.01 \log_2(0.0) = 0$

TEMA 5: Árboles de Decisión y Redes Bayesianas

5

5

Dept. de Ciència de la Computació i Intel·ligència Artificial  
 Dip. de Ciència de la Computació i Intel·ligència Artificial  
 Universitat d'Alacant  
 Universitat de Alicante

Sistemas Inteligentes

## Entropía condicionada

■ **Definición:**

- Entropía de la distribución de Y **condicionada** a X.
- Una entropía condicionada **menor** que  $E(Y)$  indica que el conocimiento de X **mejora la información** que se dispone sobre Y

$$E(Y | X) = \sum_j \text{Prob}(X = v_j) E(Y | X = v_j)$$

$v_j$	<b>Prob(<math>X = v_j</math>)</b>	<b><math>E(Y   X = v_j)</math></b>
Math	0.5	1
History	0.25	0
CS	0.25	0

$E(Y|X) = 0.5*1 + 0.25*0 + 0.25*0$ 
→

$E(Y|X) = 0.5$

X	Y
Math	Yes
Hist.	No
CS	Yes
Math	No
Math	No
CS	Yes
Hist.	No
Math	Yes

$E(Y) = 1$   

$E(Y|X) = 0.5$

TEMA 5: Árboles de Decisión y Redes Bayesianas

6

6

## Ganancia de información

### Definición:

- Medida de **cuanto ayuda el conocer** el valor de una variable aleatoria  $X$  para conocer el verdadero valor de otra  $Y$ .
- En nuestro caso,  $X$  es un **atributo** de un ejemplo dado mientras que  $Y$  es la **clase** a la que pertenece el ejemplo.
- Una alta ganancia implica que el atributo  $X$  permite **reducir la incertidumbre de la clasificación** del ejemplo de entrada.

$$IG(Y | X) = E(Y) - E(Y | X)$$

X	Y
Math	Yes
History	No
CS	Yes
Math	No
Math	No
CS	Yes
History	No
Math	Yes

$$E(Y) = 1$$

$$E(Y|X) = 0.5$$

$$IG(Y | X) = 1 - 0.5 = 0.5$$

## Algoritmo recursivo

```

Algoritmo ID3(ejemplos, atributos) {
  Si atributos = ∅ o MISMA CLASE(ejemplos) {
    C ← CLASE MAYORITARIA(ejemplos)
    N ← CREATR NODO HOJA(C)
  }
  Sino {
    amax ← maxA ∈ atributos G(ejemplos, A)
    N ← CREATR NODO(amax)
    Para cada vi ∈ VALORES(amax) {
      ejemplosvi ← {elementos de ejemplos con valor vi para amax}
      AÑADIR HIJO(N, ID3(ejemplosvi, atributos - amax))
    }
  }
  Devolver N
}

```

Dept. de Ciència de la Computació i Intel·ligència Artificial  
 Dip. de Ciència de la Computació i Intel·ligència Artificial  
 Universitat d'Alacant  
 Universidad de Alicante

Sistemas Inteligentes

## Aplicación al ejemplo

■ **Entropía inicial:**

➤ Aplicando la ecuación de entropía a los datos de entrada del ejemplo tenemos:

$$E(S) = -0.4 \log_2(0.4) - 0.6 \log_2(0.6) = 0.971$$

➤ Para cada atributo (Antigüedad, Moroso, Ingresos, Fijo), calculamos la ganancia de información que obtenemos al seleccionar cada uno de ellos

G=0.09

$Prob(S < 1) = 0.3, Prob(S 1-5) = 0.4, Prob(S > 5) = 0.3$   
 $E(S < 1) = -2/3 \log_2(2/3) - 1/3 \log_2(1/3) = 0.9183$   
 $E(S 1-5) = -1/4 \log_2(1/4) - 3/4 \log_2(3/4) = 0.811$   
 $E(S > 5) = -1/3 \log_2(1/3) - 2/3 \log_2(2/3) = 0.9183$   
 $E(S < 1) * 0.3 = 0.2755$   
 $E(S 1-5) * 0.4 = 0.3244$   
 $E(S > 5) * 0.3 = 0.2755$   
 $H(\text{Conceder} | \text{Antigüedad}) = 0.2755 + 0.3244 + 0.2755 = 0.8754$   
 $\text{Ganancia} = 0.971 - 0.8754 = 0.09$

TEMA 5: Árboles de Decisión y Redes Bayesianas

9

9

Dept. de Ciència de la Computació i Intel·ligència Artificial  
 Dip. de Ciència de la Computació i Intel·ligència Artificial  
 Universitat d'Alacant  
 Universidad de Alicante

Sistemas Inteligentes

## Aplicación al ejemplo

TEMA 5: Árboles de Decisión y Redes Bayesianas

10

10

## Extensiones del algoritmo

### Extensiones:

- **Atributos numéricos:** ID3 sólo trabaja con atributos discretos. Si se usan **atributos continuos** hay que **descomponerlos en rangos**. Para ello se ordenan los ejemplos según el valor y se toman como puntos límite los puntos medios de aquellos en que se cambie de clase.

				825	950	1150						
<b>Ejemplo</b>	8	10	6	2	1	9	3	5	4	7		
<b>Ingresos</b>	450	530	650	800	850	1050	1250	1400	1600	3000		
<b>Crédito</b>	no	no	no	no	sí	no	sí	sí	sí	sí		

- **Atributos con gran número de valores.** Se forman grupos pequeños de ejemplos que pueden ser **homogéneos por casualidad**. Debe introducirse un elemento corrector que **penalice atributos con un elevado número de valores (ganancia normalizada)**:

$$G_N(S, A) = \frac{G(S, A)}{\sum_{v_i \in V(A)} -p_{v_i} \log_2 p_{v_i}}$$

- **Sobre-entrenamiento.** Comprobación de capacidad de generalización

## Ejercicios

Objetivo: Dado el conjunto de entrenamiento, aprender el concepto “Días en los que se juega al tenis” obteniendo el árbol de decisión mediante el algoritmo ID3

Ej.	CIELO	TEMPERATURA	HUMEDAD	VIENTO	JUGAR TENIS
D <sub>1</sub>	SOLEADO	ALTA	ALTA	DÉBIL	-
D <sub>2</sub>	SOLEADO	ALTA	ALTA	FUERTE	-
D <sub>3</sub>	NUBLADO	ALTA	ALTA	DÉBIL	+
D <sub>4</sub>	LLUVIA	SUAVE	ALTA	DÉBIL	+
D <sub>5</sub>	LLUVIA	BAJA	NORMAL	DÉBIL	+
D <sub>6</sub>	LLUVIA	BAJA	NORMAL	FUERTE	-
D <sub>7</sub>	NUBLADO	BAJA	NORMAL	FUERTE	+
D <sub>8</sub>	SOLEADO	SUAVE	ALTA	DÉBIL	-
D <sub>9</sub>	SOLEADO	BAJA	NORMAL	DÉBIL	+
D <sub>10</sub>	LLUVIA	SUAVE	NORMAL	DÉBIL	+
D <sub>11</sub>	SOLEADO	SUAVE	NORMAL	FUERTE	+
D <sub>12</sub>	NUBLADO	SUAVE	ALTA	FUERTE	+
D <sub>13</sub>	NUBLADO	ALTA	NORMAL	DÉBIL	+
D <sub>14</sub>	LLUVIA	SUAVE	ALTA	FUERTE	-

Dept. de Ciència de la Computació i Intel·ligència Artificial  
 Dipn. de Ciència de la Computació i Intel·ligència Artificial  
 Universitat d'Alacant  
 Universitat de Alicante

Sistemas Inteligentes

## Ejercicios

**HUMEDAD**

```

      graph TD
        H[HUMEDAD] -- ALTA --> A["[3+, 4-]"]
        H -- NORMAL --> N["[6+, 1-]"]
      
```

**VIENTO**

```

      graph TD
        V[VIENTO] -- Débil --> D["[6+, 2-]"]
        V -- Fuerte --> F["[3+, 3-]"]
      
```

**CIELO**

```

      graph TD
        C[CIELO] -- SOLEADO --> S["[2+, 3-]"]
        C -- NUBLADO --> N["[4+, 0-]"]
        C -- LLUVIA --> L["[3+, 2-]"]
      
```

**TEMPERATURA**

```

      graph TD
        T[TEMPERATURA] -- ALTA --> A["[2+, 2-]"]
        T -- SUAVE --> S["[4+, 2-]"]
        T -- BAJA --> B["[3+, 1-]"]
      
```

TEMA 5: Árboles de Decisión y Redes Bayesianas

13

13

Dept. de Ciència de la Computació i Intel·ligència Artificial  
 Dipn. de Ciència de la Computació i Intel·ligència Artificial  
 Universitat d'Alacant  
 Universitat de Alicante

Sistemas Inteligentes

## Ejercicios

- Entropía inicial:  $\text{Ent}([9^+, 5^-]) = 0,94$
- Selección del atributo para el nodo raíz:
  - $\text{Ganancia}(D, \text{HUMEDAD}) = 0,94 - \frac{7}{14} \cdot \text{Ent}([3^+, 4^-]) - \frac{7}{14} \cdot \text{Ent}([6^+, 1^-]) = 0,151$
  - $\text{Ganancia}(D, \text{VIENTO}) = 0,94 - \frac{8}{14} \cdot \text{Ent}([6^+, 2^-]) - \frac{6}{14} \cdot \text{Ent}([3^+, 3^-]) = 0,048$
  - $\text{Ganancia}(D, \text{CIELO}) = 0,94 - \frac{5}{14} \cdot \text{Ent}([2^+, 3^-]) - \frac{4}{14} \cdot \text{Ent}([4^+, 0^-]) - \frac{5}{14} \cdot \text{Ent}([3^+, 2^-]) = 0,246$  (mejor atributo)
  - $\text{Ganancia}(D, \text{TEMPERATURA}) = 0,94 - \frac{4}{14} \cdot \text{Ent}([2^+, 2^-]) - \frac{6}{14} \cdot \text{Ent}([4^+, 2^-]) - \frac{4}{14} \cdot \text{Ent}([3^+, 1^-]) = 0,02$
- El atributo seleccionado es CIELO


TEMA 5: Árboles de Decisión y Redes Bayesianas

14

14

## Ejercicios

Árbol parcialmente construido:



## Ejercicios

- Selección del atributo para el nodo  $\text{CIELO} = \text{SOLEADO}$
- $D_{\text{SOLEADO}} = \{D_1, D_2, D_8, D_9, D_{11}\}$  con entropía  $\text{Ent}([2^+, 3^-]) = 0,971$ 
  - $\text{Ganancia}(D_{\text{SOLEADO}}, \text{HUMEDAD}) = 0,971 - \frac{3}{5} \cdot 0 - \frac{2}{5} \cdot 0 = 0,971$  (mejor atributo)
  - $\text{Ganancia}(D_{\text{SOLEADO}}, \text{TEMPERATURA}) = 0,971 - \frac{2}{5} \cdot 0 - \frac{2}{5} \cdot 1 - \frac{1}{5} \cdot 0 = 0,570$
  - $\text{Ganancia}(D_{\text{SOLEADO}}, \text{VIENTO}) = 0,971 - \frac{2}{5} \cdot 1 - \frac{3}{5} \cdot 0,918 = 0,019$
- El atributo seleccionado es HUMEDAD

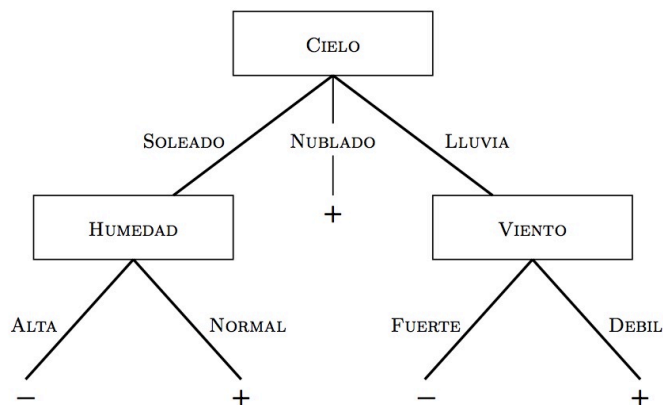


## Ejercicios

- Selección del atributo para el nodo CIELO=LLUVIA:
- $D_{LLUVIA} = \{D_4, D_5, D_6, D_{10}, D_{14}\}$  con entropía  $Ent([3^+, 2^-]) = 0,971$ 
  - $Ganancia(D_{LLUVIA}, HUMEDAD) = 0,971 - \frac{2}{5} \cdot 1 - \frac{3}{5} \cdot 0,918 = 0,820$
  - $Ganancia(D_{LLUVIA}, TEMPERATURA) = 0,971 - \frac{3}{5} \cdot 0,918 - \frac{2}{5} \cdot 1 = 0,820$
  - $Ganancia(D_{LLUVIA}, VIENTO) = 0,971 - \frac{3}{5} \cdot 0 - \frac{2}{5} \cdot 0 = 0,971$  (mejor atributo)
- El atributo seleccionado es VIENTO

## Ejercicios

- Árbol finalmente aprendido:



## Parte 2: Redes Bayesianas

Probabilidad como medida de incertidumbre

Teorema de Bayes

Redes Bayesianas

Inferencia mediante redes Bayesianas

- Inferencia Exacta
- Ejemplos
- Inferencia aproximada
  - Muestreo directo
  - Muestreo por rechazo
  - Muestreo Gibbs

Para saber más

19

## Teorema de Bayes

Sabemos que:

$$\begin{aligned} P(A|B) P(B) &= P(A, B) \\ P(B|A) P(A) &= P(B, A) = P(A, B) \end{aligned}$$

Regla de Bayes

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)} = \alpha \cdot P(B|A)P(A)$$

Constante de normalización  $P(B)$

$$P(B) = \sum_i P(B|A_i)P(A_i)$$

Regla de la cadena

$$\begin{aligned} P(A, B) &= P(A)P(B|A) \\ P(A, B, C) &= P(A)P(B|A)P(C|B, A) \end{aligned}$$

20

## Redes Bayesianas (I)

Una red bayesiana es:

- Un grafo acíclico dirigido para representar dependencias entre variables y mostrar una descripción escueta de cualquier distribución de probabilidad conjunta completa

Esta formada por

- Un conjunto de variables aleatorias que forman los nodos de la red. Cada nodo  $X$  tendrá adjunta una distribución  $P(X|\text{Padres}(X))$
- Un conjunto de enlaces que determinan la influencia (dependencia) entre nodos. Si  $X$  se conecta con  $Y$  se dice que  $X$  influye a  $Y$


Su finalidad principal es calcular la distribución conjunta de las variables nodo

21

## Redes Bayesianas (II) Semántica

Dada la siguiente red bayesiana,


¿Qué distribución representa



## Redes Bayesianas (III)

### Semántica

- $P(T,R,A,J,M) =$



$$P(T) \cdot P(R) \cdot P(A|T,R) \cdot P(J|A) \cdot P(M|A)$$


- ¿  $|P(T,R,A,J,M)|$  sin independencia condicional?
  - $2^5 = 32$
- ¿Y con independencia condicional?
  - $2+2+2^3+2^2+2^2 = 20$

23

## Redes Bayesianas (IV)


### Semántica

- Cobertura de Markov
  - Un nodo A es condicionalmente independiente de todos los nodos de la red dados:
    - Sus padres
    - Sus hijos
    - Los padres de sus hijos




24

Sistemas Inteligentes



Dept. de Ciència de la Computació i Intel·ligència Artificial  
 Dpto. de Ciencia de la Computación e Inteligencia Artificial



Universitat d'Alacant  
 Universidad de Alicante

## Inferencia

### ¿Para que queremos la distribución conjunta?

A partir de la distribución conjunta podemos contestar cualquier pregunta relativa a la red...

### Varios tipos de inferencia en redes Bayesianas

- Exacta (caso general)
- Casos especiales (Kim&Pearl...)
- Aproximada


25

---


 TEMA 5: Árboles de Decisión y Redes Bayesianas

25

Sistemas Inteligentes



Dept. de Ciència de la Computació i Intel·ligència Artificial  
 Dpto. de Ciencia de la Computación e Inteligencia Artificial



Universitat d'Alacant  
 Universidad de Alicante

## Inferencia exacta (I)

### Inferencia exacta general (funciona para todas la RR.BB.)

#### Regla de inferencia general

(Donde B son las variables buscadas, C las conocidas y D las desconocidas)

$$P(B | C) = \alpha \cdot \sum_D P(B, D, C)$$

Problema: Mucha complejidad

26

---

 TEMA 5: Árboles de Decisión y Redes Bayesianas

26


## Inferencia exacta(II)

### Ejemplo 1

- ¿Cuál es la probabilidad de que suene la alarma si llama María?

$$P(B | C) = \alpha \cdot \sum_D P(B, D, C)$$

$$\begin{aligned} P(R, T, A, J, M) &= \\ &= P(R) \cdot P(T) \cdot P(A | R, T) \cdot P(J | A) \cdot P(M | A) \end{aligned}$$



27

## Inferencia (III)

### Ejemplo 1

De esta manera tenemos que:

$$\begin{aligned} P(A | M) &= \alpha \cdot \sum_R \sum_T \sum_J P(R, T, A, J, M) = \\ &= \alpha \cdot \sum_R \sum_T \sum_J P(R) \cdot P(T) \cdot P(A | R, T) \cdot P(J | A) \cdot P(M | A) = \\ &= \alpha \cdot P(M | A) \cdot \sum_R \left( P(R) \sum_T \left( P(T) \cdot P(A | R, T) \cdot \underbrace{\sum_J P(J | A)}_1 \right) \right) \end{aligned}$$

28

## Inferencia (IV) Ejemplo 2

¿ $P(R|J+,M+)$ ? Si sabemos que:

$$P(T) = 0,001$$

$$P(R) = 0,002$$

$$P(J|A) =$$


A	J
0	0,05
1	0,9

$$P(A|T,R) =$$

T	R	A
0	0	0,001
0	1	0,94
1	0	0,29
1	1	0,95

$$P(M|A) =$$

A	M
0	0,01
1	0,7



29

## Inferencia (V) Ejemplo 2

De esta manera tenemos que:

$$\begin{aligned}
 P(R|J,M) &= \alpha \sum_T \sum_A P(R,T,A,J,M) = \\
 &= \alpha \sum_T \sum_A P(R) \cdot P(T) \cdot P(A|R,T) \cdot P(J|A) \cdot P(M|A) = \\
 &= \alpha \cdot P(R) \cdot \sum_T \left( P(T) \cdot \sum_A (P(A|R,T) \cdot P(J|A) \cdot P(M|A)) \right)
 \end{aligned}$$

30

Dept. de Ciència de la Computació i Intel·ligència Artificial  
 Dpto. de Ciencia de la Computación e Inteligencia Artificial  
 Universitat d'Alacant  
 Universidad de Alicante

Sistemas Inteligentes

## Inferencia (VI)

### Ejemplo 2

Para calcular descomponemos utilizando un árbol:

$$\alpha \cdot P(R) \cdot \sum_T P(T) \cdot \sum_A P(A | R, T) \cdot P(J | A) \cdot P(M | A)$$

31

TEMA 5: Árboles de Decisión y Redes Bayesianas

31

Dept. de Ciència de la Computació i Intel·ligència Artificial  
 Dpto. de Ciencia de la Computación e Inteligencia Artificial  
 Universitat d'Alacant  
 Universidad de Alicante

Sistemas Inteligentes

## Inferencia (VII)

### Ejemplo 2

P(R J,M)		P(¬R J,M)	
1 P(A R,T)*P(J A)*P(M A)	0,5985	1 P(A ¬R,T)*P(J A)*P(M A)	0,1827
P(¬A R,T)*P(J,¬A)*P(M ¬A)	0,000025	P(¬A ¬R,T)*P(J,¬A)*P(M ¬A)	0,000355
P(T)* SUM 1	0,00059853	P(T)* SUM 1	0,00018306
2 P(A R,¬T)*P(J A)*P(M A)	0,5922	2 P(A ¬R,¬T)*P(J A)*P(M A)	0,00063
P(¬A R,¬T)*P(J,¬A)*P(M ¬A)	0,00003	P(¬A ¬R,¬T)*P(J,¬A)*P(M ¬A)	0,0004995
P(¬T)* SUM 2	0,59163777	P(¬T)* SUM 2	0,00112856
<b>TOTAL R+</b>	<b>0,00118447</b>	<b>TOTAL ¬R</b>	<b>0,00130899</b>

P(R|J,M)= R    0,47503178  
 ¬R    0,52496822

32

TEMA 5: Árboles de Decisión y Redes Bayesianas

32



## Inferencia (VIII)

### Ejercicio 1

¿ $P(J|R)$ ?

$$\begin{aligned}
 P(J | R) &= \sum_T \sum_A \sum_M P(R) \cdot P(T) \cdot P(A | R, T) \cdot P(J | A) \cdot P(M | A) = \\
 &= P(R) \cdot \sum_T (P(T) \cdot \sum_A (P(A | R, T) \cdot P(J | A) \cdot \sum_M P(M | A)))
 \end{aligned}$$


33

## Inferencia exacta en poliárboles

Existen algoritmos más eficientes para tipos específicos de redes

Modelo de Kim y Pearl

- Método de inferencia para redes bayesianas.
- Solo aplicable a un poliárbol.
  - No existe más de un camino entre cada pareja de nodos
- Se basa en el paso de dos tipos de mensajes entre nodos
  - Para actualizar la credibilidad
  - Para introducir nueva evidencia
- Se puede calcular en tiempo lineal



34

Sistemas Inteligentes

## Inferencia aproximada (I)

Sobre la inferencia exacta

- Redes con conexión múltiple son intratables utilizando inferencia exacta
- Complejidad NP-hard en el caso general

Inferencia utilizando algoritmos de muestreo aleatorio (Monte Carlo)

- Existen varios algoritmos
  - Muestreo directo
  - Muestreo por rechazo
  - Gibbs Sampling

35

TEMA 5: Árboles de Decisión y Redes Bayesianas

35

Sistemas Inteligentes

## Inferencia aproximada (II)

### Muestreo directo

- rb: red Bayesiana
- ALGORITMO **Muestreo\_Directo**(rb) retorna un evento extraído de rb
  - $X = \langle \text{vector de sucesos con } n \text{ elementos} \rangle$
  - Para cada variable  $X_i$  en  $X_1, \dots, X_n$  hacer
    - $X_i = \text{Obtener una muestra aleatoria de } P(X_i | \text{Padres}(X_i))$
  - Devolver X

Para responder cualquier pregunta de la red

- Obtener un vector de eventos  $X[]$
- Contar apariciones en  $X[]$  de las evidencias
- Dividir por suficientesMuestras

36

TEMA 5: Árboles de Decisión y Redes Bayesianas

36

Dept. de Ciència de la Computació i Intel·ligència Artificial  
 Diplo. de Ciència de la Computació i Intel·ligència Artificial  
 Universitat d'Alacant  
 Universidad de Alicante

Sistemas Inteligentes

## Inferencia aproximada (III)

### Ejemplo de muestreo de una red mediante muestreo directo

$P(T) = 0,001; P(R) = 0,002$

$P(A|T,R)=$

T	R	A
0	0	0,001
0	1	0,29
1	0	0,94
1	1	0,95

$P(J|A) =$


A	J
0	0,05
1	0,9

$P(M|A)=$

A	J
0	0,01
1	0,7

- Muestreo a partir de  $P(\text{Terremoto}) = \langle 0,001 \ 0,999 \rangle$ .  
**supongamos (s.)** que devuelve *falso*
- Muestreo( $P(\text{Robo})$ ) s. devuelve *falso*
- Muestreo( $P(\text{Alarma} | \langle \text{Robo}=\text{falso}, \text{Terremoto}=\text{falso} \rangle)$ )  
s. devuelve *cierto*
- Muestreo( $P(\text{Juan} | \langle A=\text{cierto} \rangle)$ )  
s. Devuelve *cierto*
- Muestreo( $P(\text{Maria} | \langle A=\text{cierto} \rangle)$ )  
s. Devuelve *falso*
- $X = \langle \text{falso}, \text{falso}, \text{cierto}, \text{cierto}, \text{falso} \rangle$

37



37

Dept. de Ciència de la Computació i Intel·ligència Artificial  
 Diplo. de Ciència de la Computació i Intel·ligència Artificial  
 Universitat d'Alacant  
 Universidad de Alicante

Sistemas Inteligentes

## Inferencia aproximada (IV)

### Ejemplo de uso

$\text{¿}P(R|J,M)\text{?}$

$P(T) = 0,001;$

$P(R) = 0,00$

$P(A|T,R)=$

T	R	A
0	0	0,001
0	1	0,29
1	0	0,94
1	1	0,95

$P(J|A) =$


A	J
0	0,05
1	0,9

$P(M|A)=$

A	J
0	0,01
1	0,7

- Para obtener  $P(R|J,M)$
- $C = \text{Contar } X[ ]$  que cumpla este patrón  
 $X = \langle ?, \text{cierto}, ?, \text{cierto}, \text{cierto} \rangle$
- Devolver  $C/\text{numeroDeMuestras}$

38



38

## Inferencia aproximada (V)

¿Problema del muestreo directo?

Otros tipos de muestreo aleatorio

- Muestreo por rechazo
- Gibbs Sampling

39

## Inferencia aproximada (VI)

### Muestreo por rechazo

• ALGORITMO **Muestreo\_por\_Rechazo**( $B, c, rb$ ) retorna estimación  $P(B|c)$

• Para  $j = 1$  hasta  $\text{num\_muestras}$  hacer

- $x = \text{Muestro\_Directo}(rb)$
- Si  $x$  es consistente con la evidencia  $c$ :
- $N[y] = N[y] + 1$ , donde  $y$  es el valor de  $B$  en  $x$

• Devolver  $\text{Normalizar}(N)$

Entradas:

- $B$ : variable buscada (pregunta)
- $c$ : valores observados de las variables conocidas  $C$
- $rb$ : red bayesiana

Variables locales:


- $N$ : vector de recuento para cada valor de  $B$ , inicialmente 0

40

## Inferencia aproximada (VII)

### Muestreo por rechazo

Ejemplo:



Queremos estimar  $P(\text{Lluvia}|\text{Aspersor}=\text{cierto})$   
 Extraemos 100 muestras, de las cuales 73 tienen el aspersor apagado  
 Nos quedamos con las 27 que coinciden con la evidencia  
 De las 27:

- En 8 Lluvia = cierto
- En 19 Lluvia es falso

$$P(\text{Lluvia}|\text{Aspersor}=\text{cierto}) = \text{Normalizar}(<8,19>) = <0.296, 0.704>$$

41

## Inferencia aproximada (VIII)

### Muestreo por Gibbs (MCMC)

- ALGORITMO  
**Muestreo\_por\_Gibbs**( $B, c, rb, N$ ) retorna estimación  $P(B|c)$
- Inicializar  $x$  con valor aleatorios para las variables en  $Z$
- Para  $j = 1$  hasta num\_muestras hacer
  - Para cada  $Z_i$  en  $Z$  hacer
    - $x[Z_i] = \text{muestrear } P(Z_i|\text{mb}(Z_i))$
    - $N[x] = N[x] + 1$  donde  $x$  es el valor de  $B$  en  $x$
- Devolver  $\text{Normalizar}(N)$

Entradas:

- $B$ : variable buscada (pregunta)
- $c$ : valores observados de las variables conocidas  $C$

- $rb$ : red bayesiana

Variables locales:

- $N$ : vector de recuento para cada variable  $B$  (inicialmente vale 0)
- $Z$ , las variables sin evidencia en  $rb$
- $x$ : el estado de la red, copiado inicialmente de  $c$


Funciones

- $\text{mb}()$  retorna la cobertura de Markov un nodo

42

## Inferencia aproximada (IX)

### Ejemplo



Queremos estimar  $P(\text{Lluvia}|\text{Aspersor}=\text{cierto}, \text{Césped}=\text{cierto})$

Las variables conocidas: Aspersor y Césped, se fijan a su valor.

Las variables desconocidas: Nublado y Lluvia se establecen aleatoriamente.

Imaginemos que el estado inicial es: [cierto, cierto, falso, cierto]

Ahora las variables sin evidencia se muestrean repetidamente en orden arbitrario. Por ejemplo

- Se muestrea Nublado, dado su recubrimiento de Markov. Por tanto extraemos de  $P(\text{Nublado}|\text{Aspersor}=\text{cierto}, \text{Lluvia}=\text{Falso})$ . Asumamos que el resultado es falso y por tanto el nuevo estado es [falso, cierto, falso, cierto]
- Se muestrea Lluvia dado su recubrimiento:  $P(\text{Lluvia}|\text{Nublado}=\text{falso}, \text{aspersor}=\text{cierto}, \text{cesped}=\text{cierto})$ . Asumamos que el resultado es cierto. El nuevo estado es [falso, cierto, cierto, cierto]

Todo estado visitado mediante este proceso es una muestra que contribuye a estimar la pregunta

Por ejemplo, si durante el proceso se visitan 20 estados donde lluvia es cierto y 60 donde es falso

$$P(L|A=\text{cierto}, C=\text{cierto}) = \text{Normalizar}(\langle 20, 60 \rangle) = \langle 0.25, 0.75 \rangle$$

## Bibliografía

- Escolano et al. [Inteligencia Artificial](#). Thomson-Paraninfo 2003. Capítulo 4.
- Mitchel, [Machine Learning](#). McGraw Hill, Computer Science Series. 1997
- Cover, Thomas, [Information Theory](#). Wiley & Sons, New York 1991